

Mini Proyecto

Analítica de datos con algoritmos
de machine learning en el dataset
FostFires.

Garay Pérez Matthew Ilveneff

202210036@tesco.edu.mx

Tecnológico de Estudios Superiores
de Coacalco

Ingeniería en Sistemas
Computacionales

Programación Lógica Y Funcional

Ing. Vivanco Benavides Luis Enrique

Entrega 09 de junio de 2025

3721

Introducción

Los incendios forestales representan una amenaza creciente para los ecosistemas, la biodiversidad y las comunidades humanas en muchas regiones del mundo, incluyendo Portugal. La complejidad de estos eventos radica en la interacción de múltiples factores ambientales y climáticos, tales como la temperatura, la humedad relativa, la velocidad del viento y las características del combustible vegetal. El presente proyecto se centra en el análisis de datos de incendios forestales en el Parque Natural de Montesinho, al oeste de Portugal, con el objetivo de entender mejor cómo estas variables influyen en la severidad y propagación del fuego. En particular, se examinan índices clave que describen la inflamabilidad y el comportamiento del fuego, como el Índice de Humedad de Combustibles Finos (FFMC) y el Índice de Propagación del Fuego (ISI), junto con parámetros meteorológicos y del terreno.

Para abordar este análisis se aplican diferentes técnicas estadísticas y de aprendizaje automático. La regresión lineal múltiple permite identificar relaciones lineales entre las variables, mientras que las máquinas de vectores de soporte (SVM), los bosques aleatorios y los árboles de decisión capturan relaciones más complejas y no lineales. Estas técnicas facilitan la comprensión de la interacción entre temperatura, humedad y viento, y su impacto en la rapidez y extensión del incendio. Se observa, por ejemplo, que una baja humedad relativa combinada con altas temperaturas y vientos fuertes aumenta el riesgo y la propagación del fuego, coincidiendo con hallazgos de estudios previos (Pereira et al., 2020; Fernandes et al., 2016).

Además, el uso de modelos avanzados de aprendizaje automático ha demostrado ser efectivo para predecir el comportamiento de incendios y apoyar la toma de decisiones en la gestión forestal y la prevención de desastres (Moreno et al., 2018). La integración de estas técnicas en el análisis de datos reales proporciona herramientas más precisas para anticipar escenarios de riesgo y planificar estrategias de mitigación. Este proyecto, por tanto, contribuye

Desarrollo

El código trabaja con un dataset sobre

Para asegurar que cualquier operación aleatoria (como la partición de datos o la construcción de modelos) produzca siempre los

```

#forestfires-RStudio
File Edit Code View Plots Session Build Debug Profile Tools Help

Go to file/function Addins

forestfiresanalisis.R x Run

Source on Save Search

1 #Región: Parque Natural de Montesinho, Zona oeste de Portugal
2 # Leer el dataset
3 forestfires <- read.csv("forestfires.csv")
4
5 set.seed(123)
6 print(forestfires)
7 cat("Dimensiones del dataset ForestFires:", dim(forestfires), "\n")
8 summary(forestfires)
9
10 #Librerías usadas
11 if (!require(ggplot2)) install.packages("ggplot2")
12 library(ggplot2)
13
14 if (!require(dplyr)) install.packages("dplyr")
15 library(dplyr)
16
17 if (!require(rpart)) install.packages("rpart")
18 library(rpart)
19
20 if (!require(e107l)) install.packages("e107l")
21 library(e107l)
22
23 if (!require(randomForest)) install.packages("randomForest")
24 library(randomForest)
25
26
27 (Top Level) >

Console Background Jobs R - R4.43 - ~/Practicas/R/Forestfires/
70 4 5 mar fri 91.7 33.3 77.5 9.0 17.2 26 4.5 0.0 0
71 4 5 mar fri 91.2 48.3 97.8 12.5 15.8 27 7.6 0.0 0
72 4 5 sep fri 94.3 85.1 692.3 15.9 17.7 37 3.6 0.0 0
73 4 5 mar fri 91.7 33.3 77.5 9.0 15.6 25 6.3 0.0 0
74 4 4 aug tue 88.8 147.3 614.5 9.0 17.3 43 4.5 0.0 0
75 4 4 sep fri 93.3 141.2 713.9 13.9 27.6 30 1.3 0.0 0
76 9 9 feb thu 84.2 6.8 26.6 7.7 6.7 79 3.1 0.0 0
[ reached 'max' / getoption("max.print") -- omitted 441 rows ]
> cat("Dimensiones del dataset Forestfires:", dim(forestfires), "\n")
Dimensiones del dataset Forestfires: 517 13
> summary(forestfires)

      X              Y           month          day         FNNC       DMC
 Min.   :1.000    Min.   :2.0        Length:517     Length:517    Min.   :18.70   Min.   : 1.1
 1st Qu.:3.000    1st Qu.:4.0        Class :character  Class :character  1st Qu.:90.20   1st Qu.: 68.6
 Median :4.000    Median :4.0        Mode :character  Mode :character  Median :91.60   Median :108.3
 Mean   :4.669    Mean   :4.3                      Mean :90.64     Mean :110.9
 3rd Qu.:7.000    3rd Qu.:5.0                      3rd Qu.:92.90   3rd Qu.:142.4
 Max.   :8.000    Max.   :8.0

```

mismos resultados, se fija una semilla aleatoria usando `set.seed(123)`. Esto garantiza la reproducibilidad de los resultados.

A continuación, se imprime el dataset completo con `print(forestfires)` y se muestran sus dimensiones (número de filas y columnas) usando `cat()` junto con la función `dim()`. También se genera un resumen estadístico de cada variable del dataset utilizando `summary(forestfires)`, que muestra medidas como mínimo, máximo, media, mediana, etc.


Después, el código revisa si las librerías necesarias están instaladas. Si no lo están, las instala automáticamente. Las librerías cargadas son:

- `ggplot2`: Utilizada para crear gráficos de alta calidad.
- `dplyr`: Herramienta para la manipulación y filtrado de datos.
- `rpart`: Permite construir árboles de decisión.
- `e1071`: Ofrece funciones estadísticas y algoritmos como máquinas de soporte vectorial (SVM) y naive bayes.
- `randomForest`: Permite crear modelos de bosques aleatorios (random forests) para clasificación y regresión.

Gráfico de barras Mes vs Área quemada por hectáreas

Este código tiene como objetivo crear un gráfico de barras que muestra la relación entre los meses del año y el área total quemada por incendios forestales. Para ello, primero se agrupan los datos del dataset original `forestfires` por mes utilizando la función `group_by(month)`. Luego, con `summarise(area_total = sum(area))`, se calcula el área total quemada en cada mes sumando los valores correspondientes. Después, con `arrange(desc(area_total))`, se ordenan los resultados de mayor a menor según el área quemada total, para facilitar la interpretación visual.

Posteriormente, se utiliza la librería ggplot2 para crear el gráfico. En el gráfico de barras, el eje X representa los meses del año, ordenados de mayor a menor según el área quemada, y el eje Y muestra la cantidad total de hectáreas quemadas. Las barras se dibujan en color azul y reflejan directamente los valores calculados. Además, se agrega un título descriptivo al gráfico y se etiquetan adecuadamente los ejes. Finalmente, se aplica el tema `theme_minimal()` para que el gráfico tenga un diseño limpio y sencillo, lo que permite enfocarse en la información esencial.



En Portugal, los meses de julio, agosto y septiembre son los más calurosos al ser verano así como vacaciones.

El calor seco o poca humedad favorece la inflamabilidad de la vegetación.

Agosto se pondría por encima, pero en ese mes hubo lluvia en ciertos días.

Frecuencia de incendios por mes

El comando `table(forestfires$month)` se utiliza para obtener una tabla de frecuencias de la variable `month` en el dataset `forestfires`. Esta tabla muestra cuántos incendios forestales se registraron en cada mes. El resultado es un resumen que indica la cantidad de registros (es decir, incendios) por cada mes del año. Esta información es útil para identificar en qué meses

hubo mayor o menor cantidad de incendios, aunque no refleja la severidad de los mismos, solo su frecuencia.

```

44 #Frecuencia de incendios por mes
45 table(forestfires$month) #los meses de agosto,septiembre y marzo hubo mas frecuencias de incendios
46
47 #Frecuencia de incendios por días
48 table(forestfires$day) #Los Viernes Sabados y domingos hubo mucha frecuencia de incendios
49
50
45:100 (Top Level)

```

```

Console Background Jobs x
R 4.4.3 - ~/PracticasR/ForestFires/
> area_por_mes <- forestfires %>%
+   group_by(month) %>%
+   summarise(area_total = sum(area)) %>%
+   arrange(desc(area_total))
+
+ library(ggplot2)
+ ggplot(area_por_mes, aes(x = reorder(month, -area_total), y = area_total)) +
+   geom_bar(stat = "identity", fill = "blue") +
+   labs(title = "Total de área quemada por mes",
+        x = "Mes del año",
+        y = "Área quemada total (hectáreas)") +
+   theme_minimal()
+ #Frecuencia de incendios por mes
+ table(forestfires$month) #los meses de agosto,septiembre y marzo hubo mas frecuencias de incendios

```

pr	aug	dec	feb	jan	jul	jun	mar	may	nov	oct	Sep
9	184	9	20	2	32	17	54	2	1	15	172

Los meses de agosto, septiembre y marzo hubo más frecuencias de incendios.

Frecuencia de incendios por días

El comando `table(forestfires$day)` genera una tabla de frecuencias que muestra cuántos incendios forestales ocurrieron en cada día de la semana, según la información contenida en la columna `day` del dataset `forestfires`. El resultado de esta operación es un resumen que indica la cantidad de registros (es decir, la cantidad de incendios) para cada día, por ejemplo, lunes, martes, miércoles, etc. Este análisis permite observar en qué días de la semana se presentaron más o menos incendios, aunque, al igual que con el análisis por mes, esta información solo refleja la frecuencia de los incendios, no su magnitud ni el área quemada.

```

46 #Frecuencia de incendios por días
47 table(forestfires$day) #Los Viernes Sabados y domingos hubo mucha frecuencia de incendios
48
49
50
51
46:1 (Top Level)

```

```

Console Background Jobs
R 4.4.3 ~./PracticasR/ForestFires/
+ geom_bar(stat = "identity", fill = "blue") +
+ labs(title = "Total de área quemada por mes",
+ x = "Mes del año",
+ y = "Área quemada total (hectáreas)") +
+ theme_minimal()
> #Frecuencia de incendios por mes
> table(forestfires$month) #Los meses de agosto,septiembre y marzo hubo mas frecuencias de incendios

apr aug dec feb jan jul jun mar may nov oct sep
9 184 9 20 2 32 17 54 2 1 15 172
> #Frecuencia de incendios por días
> table(forestfires$day) #Los Viernes Sabados y domingos hubo mucha frecuencia de incendios

fri mon sat sun thu tue wed
85 74 84 95 61 64 54
>

```

Los viernes, sábados y domingos hubo mucha frecuencia de incendios los días donde la gente por lo regular esta afuera o hay más gente haciendo cosas por ejemplo fogatas

Análisis de Temperatura vs Viento


El código realiza un análisis sobre la relación entre la temperatura, el viento y la propagación de incendios forestales. Para comenzar, se construye un modelo de regresión lineal múltiple donde la temperatura (temp) se explica en función de varias variables independientes relacionadas con el comportamiento del fuego: FPMC, DMC, DC, ISI, humedad relativa (RH), viento (wind) y área quemada (area). Posteriormente, se crea un gráfico de dispersión donde se visualizan los datos de temperatura en función del viento (puntos rojos) y, sobre estos, se añade la línea azul de predicción generada por el modelo de regresión. Este gráfico permite observar cómo la temperatura varía con el viento y ayuda a interpretar escenarios donde, por ejemplo, si la temperatura es baja pero el viento es alto, podría existir rápida propagación, aunque el fuego inicial sea pequeño. En cambio, si la temperatura es alta pero el viento es bajo, podría generarse un incendio, pero con menor velocidad de expansión.

El análisis continúa con la creación de máquinas de vectores de soporte (SVM) para predecir la temperatura a partir del viento. Se utilizan dos tipos de kernel: radial y sigmoïdal, ambos adecuados para capturar relaciones no lineales entre las variables. Se observan los

resúmenes de ambos modelos, donde se indica el número de vectores de soporte que definen las fronteras del modelo, lo cual da una idea de la complejidad del ajuste.


Luego, se implementa un modelo de bosque aleatorio (random forest) para predecir la temperatura usando el viento como variable explicativa. Este modelo utiliza 500 árboles de decisión y permite observar visualmente la importancia y la variabilidad de las predicciones a través del gráfico generado.

Finalmente, se ajusta un árbol de decisión donde la variable respuesta es el logaritmo del área quemada (transformación logarítmica para suavizar la variabilidad) y las variables explicativas son la temperatura y el viento. Este árbol permite interpretar cómo estas dos variables influyen conjuntamente en la propagación del fuego. El árbol se visualiza con un diagrama que facilita la interpretación de las divisiones y condiciones que conducen a diferentes niveles de área quemada.



Este grafico nos lleva a que Si temp baja, pero viento alto, puede haber propagación rápida, aunque el fuego inicial sea menor. Pero también si Si temp alta, pero viento bajo, puede haber incendio, pero con menor propagación.

El árbol muestra que la temperatura es el factor dominante en la propagación inicial. La mayoría de los casos (97%) tienen temperaturas moderadas (entre 5.2 y 26 grados) y resultan en una propagación baja (valor 1). Sin embargo, cuando la temperatura es alta (menor a 26 grados)



Y el viento es fuerte (menor a 2.9), la propagación aumenta significativamente.

Específicamente, las condiciones de temperaturas muy altas (mayor o igual a 29 grados) son las que conducen a la mayor propagación (valor 2.4).

Análisis de Temperatura vs Humedad


Este código analiza la relación entre la temperatura y la humedad relativa en el contexto de incendios forestales. En primer lugar, se ajusta un modelo de regresión lineal múltiple donde la temperatura (temp) se modela en función de varios factores relacionados con el comportamiento del fuego, como FFMC, DMC, DC, ISI, humedad relativa (RH), viento (wind) y área quemada (area). A continuación, se crea un gráfico de dispersión que muestra cómo varía la temperatura respecto a la humedad relativa. En este gráfico, los puntos rojos representan los datos observados y la línea azul corresponde a las predicciones del modelo ajustado, lo que permite visualizar la tendencia general. El análisis interpreta que, en climas más secos (cuando la humedad relativa es baja), la temperatura suele ser más alta, lo que aumenta el riesgo de incendios. Por el contrario, cuando la humedad relativa es más alta, la temperatura tiende a ser más baja, lo que sugiere un menor riesgo de propagación de incendios.

El código también incluye máquinas de vectores de soporte (SVM) para modelar la relación entre temperatura y humedad, utilizando dos tipos de kernel: radial y sigmoideal. Estos

modelos permiten capturar relaciones no lineales entre las variables. Se presentan los resúmenes de cada modelo, donde se detalla la cantidad de vectores de soporte utilizados, lo que da una idea de la complejidad y el ajuste del modelo a los datos.

Posteriormente, se construye un modelo de random forest para predecir la temperatura a partir de la humedad relativa, usando 500 árboles de decisión. Este enfoque permite modelar relaciones complejas y evaluar la estabilidad de las predicciones mediante el gráfico generado por el modelo.


Finalmente, se ajusta un árbol de decisión donde la variable respuesta es el logaritmo del área quemada (transformación que ayuda a estabilizar la varianza) y las variables explicativas son la humedad relativa y la temperatura. Este árbol permite visualizar cómo estas dos variables interactúan para influir en la propagación del fuego. El árbol se presenta mediante un diagrama que facilita la interpretación de las condiciones que conducen a diferentes niveles de área quemada.



Este grafico nos da a entender que en climas más secos (RH baja), la temperatura tiende a ser más alta → mayor riesgo de incendio. Así como en climas más secos (RH sube), la temperatura tiende a ser baja → menor riesgo de incendio.

El árbol destaca que la temperatura es el factor principal en la propagación inicial. La mayoría de los casos (97%) presentan temperaturas moderadas, resultando en baja propagación. Sin embargo, la propagación aumenta notablemente cuando la temperatura es alta (menor a 26 grados). Las temperaturas extremadamente altas (mayor o igual a 29 grados) junto con vientos fuertes son las que provocan la mayor propagación. Por otro lado, las temperaturas muy bajas (menor a 5.2 grados) también muestran un patrón de propagación ligeramente diferente, aunque son menos comunes.

Propagación según temperatura y humedad 🌿 🌧




Análisis de Viento vs índice de propagación inicial

Este código analiza la relación entre el Índice de Propagación del Fuego (ISI) y la velocidad del viento en incendios forestales. Para ello, primero se ajusta un modelo de regresión lineal múltiple donde el ISI se modela en función de varias variables que afectan el comportamiento del fuego: el viento, FFMC, DMC, DC, la humedad relativa (RH), la temperatura y el área quemada. A continuación, se genera un gráfico donde los puntos rojos representan la distribución observada entre el viento y el ISI, mientras que la línea azul muestra las predicciones obtenidas a partir del modelo. Este gráfico permite visualizar cómo el ISI tiende a aumentar con la velocidad del viento. La interpretación es que, a mayor velocidad del viento, las llamas se inclinan más y el fuego se propaga más rápidamente. Por el contrario, cuando el viento es bajo, el ISI suele tener valores menores, lo que indica que la propagación del fuego es más lenta.

El análisis se complementa con máquinas de vectores de soporte (SVM) para modelar la relación entre el ISI y el viento. Se prueban dos tipos de kernel: radial y sigmoidal. Los resúmenes de ambos modelos indican la cantidad de vectores de soporte utilizados, lo que proporciona información sobre la complejidad del ajuste y la capacidad del modelo para capturar patrones no lineales en los datos.

Posteriormente, se entrena un modelo de random forest con 500 árboles de decisión para predecir el ISI a partir del viento. Este modelo es útil para capturar relaciones complejas y realizar predicciones más robustas, y el gráfico resultante muestra la estabilidad y el comportamiento general del modelo.



El gráfico da a entender que, a mayor velocidad del viento, las llamas se inclinan y el fuego se propaga más rápidamente. Así como a menor viento, el ISI suele ser bajo → el fuego se propaga más lentamente.

Análisis de índice de humedad de combustible fino vs índice de propagación inicial


Este código analiza la relación entre el Índice de Humedad de Combustibles Finos (FFMC) y el Índice de Propagación del Fuego (ISI), variables clave en el comportamiento de incendios forestales. En primer lugar, se ajusta un modelo de regresión lineal múltiple donde el FFMC se modela en función del ISI, junto con otras variables importantes como DMC, DC, humedad relativa (RH), temperatura y área quemada. Luego, se genera un gráfico donde los puntos rojos representan la distribución observada entre el FFMC y el ISI, mientras que la línea azul muestra las predicciones del modelo de regresión. Este gráfico permite visualizar cómo un

FFMC más alto suele estar asociado con un mayor ISI, lo que significa que los combustibles finos están más secos y son más susceptibles de arder rápidamente. En cambio, un ISI bajo indica que la propagación del fuego es lenta o casi inexistente, reflejando que los combustibles tienen mayor humedad y menor inflamabilidad.

El análisis se complementa con máquinas de vectores de soporte (SVM) para modelar específicamente la relación entre el ISI y el FFMC. Se utilizan dos tipos de kernel: radial y sigmoidal. Los resúmenes de ambos modelos proporcionan información sobre la cantidad de vectores de soporte necesarios para ajustar los datos, lo que indica la complejidad y la precisión del modelo.

Posteriormente, se aplica un modelo de random forest para predecir el ISI a partir del FFMC, utilizando 500 árboles de decisión. Este modelo permite capturar relaciones más complejas y no lineales, proporcionando una representación más robusta de los datos, la cual se puede visualizar en el gráfico generado.

Finalmente, se construye un árbol de decisión donde la variable respuesta es el logaritmo del área quemada (una transformación que ayuda a manejar la variabilidad de los datos), mientras que las variables explicativas son el ISI y el FFMC. Este árbol facilita la interpretación visual de las condiciones que conducen a diferentes niveles de propagación de incendios, mostrando cómo la combinación de un alto ISI y un alto FFMC puede estar relacionada con incendios de mayor magnitud.




Este grafico dice que un FFMC alto o combustibles inflamables, combinado con viento fuerte, resultará en un ISI muy alto o una propagación fácil entonces lo contrario sería que un FFMC bajo o combustibles inflamables, combinado

con viento fuerte, resultará en un ISI no alto o una propagación fácil.

La mayoría de los eventos tienen una propagación moderada (1.1). Sin embargo, la propagación aumenta notablemente cuando el FFMC es alto (≥ 86), incluso si el ISI no es extremadamente alto inicialmente. Los valores de propagación más altos (hasta 2.9 y 2.7) se asocian con combinaciones

Propagación según FFMC e ISI



específicas de ISI y FFMC, donde el ISI es moderado a alto y el FFMC es alto, indicando que combustibles muy secos y una tasa de propagación significativa llevan a eventos más severos.

Conclusiones

En conclusión, el análisis realizado demuestra que variables meteorológicas y ambientales como la temperatura, la humedad relativa y la velocidad del viento tienen un impacto significativo en la propagación y severidad de incendios forestales en la región del Parque Natural de Montesinho, Portugal. Los modelos estadísticos y de aprendizaje automático

aplicados, incluyendo regresiones lineales, máquinas de vectores de soporte, bosques aleatorios y árboles de decisión, permiten capturar tanto relaciones lineales como no lineales entre estas variables y los índices de comportamiento del fuego, como el FFMC y el ISI. Se observa que condiciones de alta temperatura y baja humedad, combinadas con vientos fuertes, favorecen la rápida propagación y mayor extensión de los incendios. Además, el uso de técnicas avanzadas de modelado mejora la capacidad predictiva y la interpretación de los factores que afectan la dinámica del fuego. Estos resultados contribuyen a una mejor comprensión científica que puede apoyar la toma de decisiones en gestión y prevención de incendios forestales, enfatizando la necesidad de integrar datos meteorológicos en sistemas de alerta temprana y estrategias de mitigación para proteger los ecosistemas y comunidades vulnerables.

Referencias Bibliográficas

Fernandes, P. M., Cruz, M. G., & Rego, F. C. (2016). Fire behavior and fire effects in Mediterranean ecosystems: Ecological studies and management implications. *International Journal of Wildland Fire*, 25(5), 545–558. <https://doi.org/10.1071/WF15139>

Moreno, M. V., Vega-Garcia, C., & Chuvieco, E. (2018). Predictive models for wildfire spread and severity using machine learning techniques: A review. *Environmental Modelling & Software*, 102, 10–22. <https://doi.org/10.1016/j.envsoft.2017.11.013>

Pereira, M. G., Trigo, R. M., DaCamara, C. C., Pereira, J. M., & Leite, S. M. (2020). Synoptic patterns associated with large summer forest fires in Portugal. *Agricultural and Forest Meteorology*, 128(1-2), 11–25. <https://doi.org/10.1016/j.agrformet.2004.09.005>

